Informe TP2
Representación vectorial de texto: embeddings y búsqueda semántica

UNR · TUIA · Procesamiento de Lenguaje Natural
Integrantes: Franco Renna · Micaela Gómez · Irma Carolina Ruiz · Franco Esparza

Se compararon cuatro representaciones de 150 sinopsis de ciencia ficción: TF-IDF (línea de base léxica), el promedio de vectores de un Word2Vec propio, el promedio de vectores de SBW-vectors-300-min5 y SBERT (distiluse-base-multilingual-cased-v1). Como parte avanzada se aplicó chunking a SBERT. La evaluación usa un conjunto propio de 18 consultas (queries.json), con entre 2 y 11 libros relevantes cada una; dos de ellas (q17 y q18) no comparten ninguna palabra con sus relevantes.

1. ¿Cuánto mejor que TF-IDF?

En el promedio, ningún modelo de embeddings sin chunking supera a TF-IDF. Los embeddings ganan con claridad solo en las consultas que no comparten palabras con sus relevantes, y SBERT con chunking es el único que supera a TF-IDF en el promedio.

Modelo	precision@3	precision@5
Azar (piso)	0,036	0,036
TF-IDF	0,407	0,322
Word2Vec propio	0,296	0,211
SBW (promedio)	0,407	0,333
SBERT	0,407	0,300
SBERT con chunking	0,519	0,444
Máximo posible	0,981	0,900

Todos los modelos superan con amplitud el percentil 95 de una selección al azar (0,074 en precision@3 y 0,067 en precision@5).

En precision@3, TF-IDF, SBW y SBERT empatan (22 aciertos sobre 54 posiciones). En precision@5, SBW supera a TF-IDF por un solo acierto sobre 90 posiciones, y SBERT queda dos aciertos por debajo. Consulta por consulta, SBW gana 6, empata 6 y pierde 6 contra TF-IDF; SBERT gana 6, empata 5 y pierde 7; el Word2Vec propio pierde 10 de 18.

- Dónde gana TF-IDF: cuando las palabras de la consulta aparecen literalmente en las sinopsis relevantes. En q11 (antologías) logra 0,8 contra 0,2 de SBW y SBERT, y en q12 (Marte), 0,6 contra 0,2 y 0,4. En las 16 consultas que comparten palabras, TF-IDF tiene la mejor precision@5 (0,363).
- Dónde ganan los embeddings: en q17 y q18, sin palabras en común, TF-IDF obtiene 0 y SBW y SBERT llegan a 0,6 y 0,2. También ganan en consultas que comparten pocas palabras con sus relevantes: q07 (sociedades totalitarias: SBW 0,8 contra 0,2), q08 (telepatía) y q10 (guerras espaciales).
- Chunking: SBERT pasa de 27 a 40 aciertos en precision@5. En los libros relevantes que superan el límite de 128 tokens, el recall@10 sube de 0,40 a 0,56, aunque 28 de 80 de esos libros bajan en el ranking.

2. Qué mide y qué no mide la métrica

precision@k mide qué fracción de los k primeros resultados el grupo consideró relevante. Es una medida de lo que ve un usuario en la primera pantalla, con un criterio de relevancia propio.

No mide:

- El orden dentro del top k: un relevante en el puesto 1 vale lo mismo que en el puesto 5.
- Lo que queda fuera del top k: un libro que sube del puesto 59 al 9 no cambia la precision@5. Por eso, para el chunking se informó también la posición media de los relevantes.

- Grados de relevancia: cada libro es relevante o no lo es.

Además, tiene límites propios de este conjunto:

- Pocas consultas. Con 18 consultas, un acierto cambia la precision@5 en 0,011. Las diferencias entre TF-IDF, SBW y SBERT (de uno o dos aciertos) no alcanzan para ordenarlos.
- Techo menor que 1. Las consultas con menos de k relevantes no pueden llegar a 1: q18 tiene 2 relevantes y su máximo en precision@5 es 0,4. Por eso se informa el máximo posible junto a cada valor.
- Relevancia juzgada sobre la sinopsis, y en las largas, solo sobre su comienzo. Un libro relevante por algo que aparece al final de su sinopsis pudo no quedar marcado. El conjunto comparte así el sesgo de la truncación de SBERT, y puede subestimar la mejora del chunking.
- Similitudes no comparables entre modelos. En SBW, dos sinopsis cualesquiera tienen similitud media 0,862 y el 90 % de los pares está entre 0,75 y 0,93: el ranking se decide por centésimas. La métrica no muestra esa fragilidad; la muestra la distribución de similitudes.

3. Caso de falla: q04

q04 («extraterrestres hostiles que atacan o quieren dominar la Tierra») es la consulta con peores resultados: TF-IDF, el Word2Vec propio y SBERT no ubican ningún relevante entre los 5 primeros, y SBW ubica uno.

Libro relevante	Palabras compartidas	Tokens	TF-IDF	W2V propio	SBW	SBERT
Los últimos días de la Tierra	tierra	309	9	8	1	8
Orfanato	tierra	186	21	10	12	16
Trilogía de los Tres Cuerpos	extraterrestres, tierra	477	6	76	69	136
Barrera siniestra	ninguna	158	136	53	50	31
Los visitantes	ninguna	155	119	90	30	56

Posición de cada relevante en el ranking de 150 libros.

Hipótesis: las sinopsis no dicen lo que hace relevante al libro. El único relevante bien ubicado en los cuatro modelos, "Los últimos días de la Tierra", es el único cuya sinopsis dice al comienzo que la Tierra fue invadida por una raza extraterrestre. En "Barrera siniestra", "Los visitantes" y "Orfanato", el comienzo de la sinopsis oculta quién es el enemigo para generar intriga: habla de "el más maligno de los enemigos", de un apagón sin explicación o de proyectiles disparados desde Ganímedes. Ningún modelo puede recuperar lo que el texto no dice.

"Trilogía de los Tres Cuerpos" falla por otra razón: su sinopsis de 477 tokens empieza con texto promocional ("edición completa", "premio Hugo", "obra maestra"). TF-IDF la ubica sexta porque "extraterrestres" aparece en algún lugar del texto, pero SBERT, que solo ve los primeros 128 tokens, la deja en el puesto 136.

En lugar de los relevantes, los modelos devuelven libros con "Tierra" o "mundos" en el título, como "Expedición a la Tierra" o "Cuando chocan los mundos". Responden a la Tierra como tema, pero no a los extraterrestres hostiles como agentes de la trama.

4. Modelo elegido para producción

Elegiríamos SBERT con chunking. Es el único que supera a TF-IDF en el promedio (0,444 contra 0,322 en precision@5), recupera las consultas sin palabras en común y corre localmente, sin servicios pagos.

Criterio	TF-IDF	Word2Vec propio	SBW (promedio)	SBERT con chunking
precision@5	0,322	0,211	0,333	0,444
Costo	Mínimo: se calcula en segundos	Bajo, pero vocabulario de solo 988 palabras	Descarga de 1,1 GB y 300 dimensiones	Modelo de cientos de MB; 322 vectores de 512 dimensiones
Privacidad	Todo local	Todo local	Todo local	Todo local: las consultas no salen a ninguna API
Reproducibilidad	Total	Total con semilla y un solo hilo	Total una vez descargado	Total si se fija la versión del modelo
Dependencia de terceros	Ninguna	Ninguna	Servidor de la UNC para la descarga	Hugging Face para la descarga

La dependencia de SBERT es solo para la primera descarga y se elimina guardando una copia del modelo. Su costo es mayor que el de TF-IDF, pero con 150 libros los 322 vectores se generan en segundos.

TF-IDF sigue siendo la mejor opción cuando la consulta repite palabras literales de las sinopsis, como en q11 y q12. Una combinación de los dos rankings podría aprovechar ambos casos, pero no se midió en este trabajo. El Word2Vec propio se descarta: tiene la peor métrica y solo cubre el 51 % de las palabras de contenido del corpus. SBW no mejora a TF-IDF y su espacio discrimina poco.

La ventaja del chunking se midió con las mismas 18 consultas que el resto de los modelos, sin un conjunto aparte para confirmarla.

5. Uso de asistentes de IA

Usamos Claude (Anthropic) para resolver problemas de configuración del entorno (instalación de gensim, entorno virtual, conexión a Supabase y manejo de credenciales) y para revisar los textos de observaciones del notebook. También lo usamos como apoyo para armar las consultas de `queries.json`, sin mostrarle los resultados de los modelos. Las decisiones de diseño, la interpretación de los resultados y la verificación de que los textos coincidieran con las salidas del notebook quedaron a cargo del grupo.