Informe TP2 — Representación vectorial de texto: embeddings y búsqueda semántica

UNR · TUIA · Procesamiento de Lenguaje Natural
Integrantes: Franco Renna · Micaela Gómez · Irma Carolina Ruiz · Franco Esparza

Se compararon cuatro representaciones de 150 sinopsis de ciencia ficción: TF-IDF (línea de base léxica), el promedio de vectores de un Word2Vec propio, el promedio de vectores de `SBW-vectors-300-min5` y SBERT (`distiluse-base-multilingual-cased-v1`). Como parte avanzada se aplicó *chunking* a SBERT. La evaluación usa un conjunto propio de 18 consultas (`queries.json`), con entre 2 y 11 libros relevantes cada una, armado leyendo las sinopsis antes de ejecutar ningún buscador. Dos consultas (q17 y q18) no comparten ninguna palabra con sus libros relevantes.

Tres datos del corpus condicionan todo lo que sigue. El **Word2Vec propio** se entrenó con 19.128 palabras: su vocabulario es de 988 palabras y cubre el 51 % de las palabras de contenido de las sinopsis. En el espacio de **SBW**, dos sinopsis cualesquiera tienen similitud media 0,862 y el 90 % de los pares está entre 0,75 y 0,93: casi todo se parece a todo y el ranking se decide por centésimas. **SBERT** lee como máximo 128 tokens, y 113 de las 150 sinopsis (75 %) lo superan: se representan solo con su comienzo.

1. ¿Cuánto mejor que TF-IDF?

Modelo	precision@3	precision@5	p@5, 16 consultas que comparten palabras	p@5 en q17 / q18
Azar (piso)	0,036	0,036	0,038	0,03 / 0,01
TF-IDF	0,407	0,322	0,363	0 / 0
Word2Vec propio (promedio)	0,296	0,211	0,238	0 / 0
SBW (promedio)	0,407	0,333	0,325	0,6 / 0,2
SBERT	0,407	0,300	0,288	0,6 / 0,2
SBERT con chunking	**0,519**	**0,444**	**0,463**	**0,6 / 0**
Máximo posible	0,981	0,900	0,938	0,8 / 0,4

Promedio sobre las 18 consultas. El máximo posible es menor que 1 porque algunas consultas tienen menos de *k* libros relevantes.

Contra el azar. Todos los modelos superan con amplitud el percentil 95 de una selección al azar (0,074 en precision@3 y 0,067 en precision@5, sobre 2.000 repeticiones).

Sin chunking, los embeddings no superan a TF-IDF por un margen apreciable. En precision@3, TF-IDF, SBW y SBERT empatan (22 aciertos sobre 54 posiciones). En precision@5, SBW supera a TF-IDF por un solo acierto sobre 90 posiciones y SBERT queda dos aciertos por debajo. Consulta por consulta, SBW gana 6, empata 6 y pierde 6 contra TF-IDF; SBERT gana 6, empata 5 y pierde 7; el Word2Vec propio gana 2 y pierde 10. Con 18 consultas, estas diferencias no alcanzan para ordenar a TF-IDF, SBW y SBERT.

- **Dónde gana TF-IDF:** cuando las palabras de la consulta aparecen literalmente en las sinopsis relevantes. En q11 (antologías) logra 0,8 contra 0,2 de SBW y SBERT, y en q12 (Marte), 0,6 contra 0,2 y 0,4. En las 16 consultas que comparten palabras tiene la mejor precision@5.
- **Dónde ganan los embeddings:** en las dos consultas sin palabras en común, donde TF-IDF no puede acertar por construcción, SBW y SBERT llegan a 0,6 (q17) y 0,2 (q18). También ganan en consultas que comparten pocas palabras con sus relevantes: q07 (sociedades totalitarias: SBW 0,8 contra 0,2), q08 (telepatía: 0,6 contra 0,4) y q10 (guerras espaciales: 0,4 contra 0,2). Son solo dos consultas sin palabras en común: el resultado es un indicio, no una medida.
- **Chunking:** es el único cambio que supera a TF-IDF por un margen apreciable. En precision@5 pasa de 27 a 40 aciertos (TF-IDF tiene 29). Consulta por consulta, contra TF-IDF gana 9, empata 6 y pierde 3 (q03, q11 y q13). En los 80 pares de consulta y libro relevante truncado, el recall@10 sube de 0,40 a 0,56 y la posición media pasa de 26,3 a 18,1, aunque 28 de esos 80 pares bajan en el ranking. En q18 pierde el único acierto que tenía SBERT sin chunks.

2. Qué mide y qué no mide la métrica

precision@*k* mide qué fracción de los *k* primeros resultados fue marcada como relevante en `queries.json`. Representa lo que ve un usuario en la primera pantalla, con un criterio de relevancia propio. No mide:

- **El orden dentro del top *k*:** un relevante en el puesto 1 vale lo mismo que en el puesto 5.
- **Lo que queda fuera del top *k*:** un libro que sube del puesto 59 al 9 no cambia la precision@5. Por eso, para el chunking se informan también el recall y la posición media de los relevantes.
- **Cuántos relevantes faltaron** (recall) ni **grados de relevancia:** cada libro es relevante o no lo es.
- **La fragilidad del ranking:** en SBW los primeros puestos se separan por centésimas de similitud. La métrica no lo muestra; lo muestra la distribución de similitudes entre pares de sinopsis.

Además, tiene límites propios de este conjunto de evaluación:

- **Pocas consultas.** Con 18 consultas, un acierto cambia la precision@5 promedio en 0,011. Diferencias de uno o dos aciertos no son concluyentes.
- **Techo menor que 1.** q18 tiene 2 relevantes y su máximo en precision@5 es 0,4. Por eso se informa el máximo posible junto a cada valor.
- **Relevancia juzgada sobre la sinopsis, y en las largas, sobre su comienzo.** Un libro relevante por algo que aparece al final de su sinopsis pudo no quedar marcado. El conjunto comparte así el sesgo de la truncación de SBERT y puede subestimar la mejora del chunking.

3. Caso de falla: q04

q04 («extraterrestres hostiles que atacan o quieren dominar la Tierra») es la consulta con peores resultados: TF-IDF, el Word2Vec propio y SBERT no ubican ningún relevante entre los 5 primeros, y SBW ubica uno. La tabla muestra la posición de cada libro relevante en el ranking de 150 y en qué token de la sinopsis empieza la frase que revela a los extraterrestres.

Libro relevante	Palabras compartidas con la consulta	Token de la frase / total	TF-IDF	W2V propio	SBW	SBERT	SBERT con chunks
Los últimos días de la Tierra	tierra	51 / 309	9	8	1	8	4
Orfanato	tierra	150 / 186	21	10	12	16	3
Trilogía de los Tres Cuerpos	extraterrestres, tierra	161 / 477	6	76	69	136	7
Los visitantes	ninguna	121 / 155	119	90	30	56	9
Barrera siniestra	ninguna	116 / 158	136	53	50	31	42

Hipótesis: las sinopsis dicen lo relevante tarde y con otras palabras. El único libro bien ubicado en los cuatro modelos, "Los últimos días de la Tierra", es el único que nombra a la "raza extraterrestre" al comienzo (token 51). Las otras sinopsis demoran el giro de la trama para generar intriga: empiezan hablando de "el más maligno de los enemigos", de un apagón sin explicación o de proyectiles disparados desde Ganímedes, y recién hacia el final dicen "el dominio de la raza humana por otros seres" o "no estamos solos en el Universo". Esa frase empieza cerca o después del límite de 128 tokens de SBERT (tokens 116 a 161) y no usa las palabras de la consulta. TF-IDF falla por el vocabulario y SBERT por la truncación. En su lugar, los modelos devuelven libros con "Tierra" o "mundos" en el título: responden a la Tierra como tema, no a los extraterrestres hostiles como agentes de la trama.

La hipótesis se puso a prueba con el chunking. Cuatro de los cinco relevantes suben ("Trilogía de los Tres Cuerpos" del puesto 136 al 7, "Los visitantes" del 56 al 9) y la precision@5 de q04 pasa de 0 a 0,4. "Barrera siniestra" empeora (del 31 al 42) y para ese libro no tenemos una explicación comprobada. Es una sola consulta: vale como indicio, no como prueba.

4. Modelo elegido para producción

Elegiríamos **SBERT con chunking**. Es el único que supera a TF-IDF por un margen apreciable (40 aciertos contra 29 en precision@5), ataca la truncación, que afecta al 75 % de las sinopsis, responde a consultas que no repiten las palabras del texto y corre localmente, sin servicios pagos.

Criterio	TF-IDF	Word2Vec propio	SBW (promedio)	SBERT con chunking
precision@5	0,322	0,211	0,333	0,444
Costo	Mínimo: se calcula en segundos	Bajo, pero con vocabulario de solo 988 palabras	Descarga de 1,1 GB; 150 vectores de 300 dimensiones	Modelo de unos 500 MB; 322 vectores de 512 dimensiones (2,1 por libro)
Privacidad	Todo local	Todo local	Todo local	Todo local: las consultas no salen a ninguna API
Reproducibilidad	Total	Total con semilla fija y un solo hilo	Total una vez descargado	Total si se fija la versión del modelo
Dependencia de terceros	Ninguna	Ninguna	Servidor de la UNC, solo para la descarga	Hugging Face, solo para la descarga

La dependencia de SBERT se elimina guardando una copia del modelo. Su costo es mayor que el de TF-IDF, pero con 150 libros los 322 vectores se generan en segundos. Los vectores se guardan en Postgres con `pgvector`, y con este tamaño la búsqueda exacta es instantánea; en un catálogo grande haría falta el índice HNSW, con el cuidado de que un filtro selectivo puede reducir el recall (se reprodujo en el notebook: 2 resultados de 4 con el índice forzado).

Reservas de la elección. TF-IDF sigue siendo mejor cuando la consulta repite palabras literales de las sinopsis (q11, q12): una combinación de los dos rankings podría aprovechar ambos casos, pero no se midió. La ventaja del chunking se midió con las mismas 18 consultas que el resto, sin un conjunto aparte para confirmarla. El Word2Vec propio se descarta: tiene la peor métrica y no puede representar consultas con palabras fuera de su vocabulario. SBW no mejora a TF-IDF y su espacio discrimina poco.

5. Uso de asistentes de IA

Usamos Claude (Anthropic) y Gemini (Google): para resolver la configuración del entorno (instalación, entorno virtual, conexión a Supabase y manejo de credenciales); para revisar el notebook contra el enunciado; para escribir y corregir código; y para revisar los textos del notebook y redactar el README. El grupo ejecutó y verificó el notebook, controló que los textos coincidan con las salidas y es responsable de las decisiones y de las conclusiones.