Informe del Trabajo Práctico 3

Recomendador personalizado de libros

Procesamiento del Lenguaje Natural · Unidad 3 · TUIA · Universidad Nacional de Rosario
Grupo 11: Franco Renna · Micaela Gómez · Irma Carolina Ruiz · Franco Esparza
Docentes: Alan Geary y Juan Pablo Manson · Noviembre de 2026

1. Introducción

La cátedra entregó un catálogo de 8747 libros en el que algunas sinopsis fueron contaminadas con enlaces, mensajes promocionales y libros inexistentes. El trabajo tuvo dos partes: auditar el catálogo con varios detectores, medidos sobre la muestra etiquetada (500 libros, 20 % contaminados, dividida por libro en 350 de desarrollo y 150 de prueba, con `random_state=42`), y construir un recomendador que aprenda las preferencias de un lector, comparando TF-IDF con los embeddings del TP2 (`distiluse-base-multilingual-cased-v1`, 512 dimensiones). Los umbrales y las reglas se eligieron solo con desarrollo. El Paso 1 dejó 8592 libros: se eliminaron 1 sin sinopsis, 98 con sinopsis repetida y 56 casi duplicados (mismo autor, título parecido según `thefuzz`, veto por número de volumen y control por sinopsis).

2. Resultados

2.1 Detectores de la auditoría y costo de un falso positivo

Detector	Contaminación que detecta	Marcados	Precisión	Recall
Expresión regular	Enlaces, dominios, correos y teléfonos escritos literalmente	12	1,00	0,40
Regex + normalización	Enlaces disimulados: caracteres invisibles, letras de otro alfabeto, letras separadas, signos escritos con palabras	19	1,00	0,63
Idioma por oración	Mensajes en inglés o portugués dentro de una sinopsis en español	10	0,80	0,27
Clasificador (embeddings)	Promoción redactada en prosa, sin enlace	25	1,00	0,83
Casi duplicado	Libros inventados que copian la sinopsis de otro y agregan texto	3	1,00	0,10
Combinación	**Al menos uno marca (el idioma no decide solo)**	**29**	**1,00**	**0,97**

Tabla 1. Detectores sobre la parte de prueba de la muestra (150 libros, 30 contaminados).

La combinación supera a cada detector porque cada uno cubre un tipo distinto de contaminación. El que se escapa no tiene enlace ni otro idioma: *«Si te gustó esta reseña, compartila…»*. El reconocimiento de entidades (spaCy) sirvió para explicar y no para detectar: `MISC` aparece tres veces más en el texto insertado (formatos como PDF o EPUB) y `PER` casi tres veces más en las sinopsis legítimas, pero usar «tiene una ORG» como detector da precisión 0,33 y marcaría 89 de 350 libros.

Costo de un falso positivo. Un libro legítimo eliminado sale del catálogo limpio y nunca se puede recomendar: el error es definitivo. Un falso negativo, en cambio, se puede corregir si el lector lo encuentra en el Paso 3 (motivo «revisión manual»). Por eso el umbral del clasificador se fijó para una precisión de 0,98 en desarrollo (umbral 0,711), y el detector de idioma no decide solo: en el catálogo habría eliminado 84 libros legítimos, sobre todo oraciones en español que `langdetect` confundió con portugués. Sobre el catálogo completo se marcaron 380 libros (4,4 %) y quedaron 8212.

2.2 La etiqueta `interes` y quién valoró

`interes` es la respuesta del lector a «¿Me interesaría leer este libro?» después de leer el título y la sinopsis: 1 si le interesaría, 0 si no, y vacío si no puede decidir (preferencia desconocida, no un 0). Es una preferencia declarada sobre la descripción, no una opinión sobre el libro leído. Todas las valoraciones las dio **Franco Renna**, recorriendo en orden el catálogo limpio mezclado con `random_state=42` y antes de ver cualquier predicción. Se obtuvieron 100 respuestas válidas (30 positivas y 70 negativas), sin abstenciones ni spam sin detectar. La división 80/20 estratificada dejó 24 positivos en entrenamiento y 6 en prueba.

2.3 TF-IDF frente a embeddings en las dos tareas

Al detectar contaminación, las dos representaciones empataron a nivel libro (precisión 0,86 y recall 1,00 en prueba), y a nivel oración los embeddings tuvieron mejor precisión (0,86 frente a 0,72). Ese recall perfecto mide memorización: las 38 oraciones insertadas de prueba repiten moldes que ya estaban en desarrollo. Con seis frases promocionales redactadas de nuevo, TF-IDF reconoció 2 y los embeddings 6, y ninguno marcó las seis frases literarias de control. TF-IDF sirve para cadenas literales, como una URL; los embeddings generalizan a frases nuevas con el mismo sentido.

Modelo	Precisión	Recall	F1	Aciertos	F1 en validación cruzada (5×10)
A · TF-IDF	1,00 (1 de 1)	0,17 (1 de 6)	0,29	15 / 20	0,01 ± 0,07
B · embeddings	0,38 (3 de 8)	0,50 (3 de 6)	0,43	12 / 20	0,48 ± 0,17

Tabla 2. Clasificación de preferencias: clase 1 sobre los 20 libros de prueba, y validación cruzada sobre los 80 de entrenamiento.

Al clasificar preferencias la diferencia fue mucho mayor. Con 80 sinopsis y un vocabulario de 4118 palabras, cada libro de prueba comparte pocas palabras con los de entrenamiento: TF-IDF asignó probabilidades entre 0,40 y 0,50 y predijo un solo positivo. Sus 15 aciertos equivalen a responder «no» a todo (14), y en la validación cruzada su F1 medio fue 0,01. La diferencia es mayor en esta tarea porque el interés depende del tema y del género, que cada sinopsis expresa con palabras distintas, mientras que el spam repite cadenas casi literales.

2.4 ¿Algún clasificador mejoró las recomendaciones por similitud?

Lista (mismos 20 libros de prueba)	Aciertos en el top 5	precision@5
TF-IDF + clasificador	2	0,40
Embeddings + clasificador	**3**	**0,60**
Similitud con el perfil del lector	2	0,40
Azar (proporción de 1 en prueba)	—	0,30

Tabla 3. precision@5 de las tres listas.

Sí: el clasificador con embeddings superó a la similitud, aunque por un solo libro, así que la diferencia no es concluyente. El perfil promedia los embeddings de 24 libros que mezclan ciencia ficción, fantasía, suspenso y divulgación, y queda en un punto intermedio: sus cuatro primeros puestos tienen similitudes casi iguales (0,47 a 0,49) y tres son libros que el lector rechazó, como *El Hakim*. El clasificador aprende también de los 56 negativos y puede alejarse de ellos. TF-IDF no mejoró a la similitud: sus puntuaciones van de 0,490 a 0,504 y el orden depende de diferencias mínimas.

2.5 Error encontrado y límites del experimento

Error. *Variación*, una novela romántica juvenil sobre una bailarina, recibió 0,58 del modelo con embeddings, y el lector la había valorado con 0. Una hipótesis es que el modelo reconoce el registro de novela juvenil, que comparte con libros que le interesan, pero con 24 positivos no distingue la aventura del romance. También quedaron errores identificados en la auditoría (el spam sin enlace que se escapa y *La Divina Comedia* duplicada en dos traducciones) y en el resumen extractivo, que en *Hijo de las sombras* pierde al protagonista y el conflicto.

Límites.

- Con 20 libros de prueba, un solo libro cambia el F1 en más de 0,1; el desvío de 0,17 en validación cruzada es parte del resultado.
- Las preferencias son de un único lector y sobre sinopsis, no sobre lecturas.
- La muestra de auditoría está enriquecida al 20 % y repite moldes, así que la precisión real sobre el catálogo (4 a 5 % de contaminados) será menor; la clave oculta de la cátedra lo va a medir.
- Los umbrales se eligieron con probabilidades calculadas sobre los mismos datos de desarrollo con los que se entrenó el clasificador, que resultan optimistas.
- El comentario del lector sobre las cinco recomendaciones del catálogo (le interesan 3 de 5) es cualitativo y no entra en las métricas.

3. Conclusiones

La auditoría combinada detectó 29 de los 30 contaminados de prueba sin eliminar libros legítimos, y cada detector aportó un tipo de contaminación distinto. En la auditoría, TF-IDF y embeddings empataron sobre la muestra, pero los embeddings generalizaron mejor a promoción redactada de otra forma (6 de 6 contra 2 de 6). Al aprender preferencias la ventaja fue mucho mayor: TF-IDF casi no aprende con 80 ejemplos. El clasificador con embeddings fue el mejor recomendador (precision@5 de 0,60 frente a 0,30 del azar). Como trabajo futuro se propone reunir más valoraciones, medir la generalización dividiendo la muestra por molde de mensaje y elegir los umbrales con validación cruzada dentro de desarrollo.

4. Uso de asistentes de IA

Usamos Claude (Anthropic) para configurar el entorno, revisar el notebook contra el enunciado y el material de la Unidad 3, escribir y corregir código y redactar los textos de observaciones y este informe. El grupo ejecutó y verificó el notebook y es responsable de las decisiones y de las conclusiones.