Informe del Trabajo Práctico 3

Recomendador personalizado de libros

Procesamiento del Lenguaje Natural - Unidad 3 · TUIA - Universidad Nacional de Rosario
Grupo 11: Franco Renna · Micaela Gómez · Irma Carolina Ruiz · Franco Esparza
Docentes: GEARY, Alan y MANSON, Juan Pablo - Fecha de entrega: noviembre de 2026

---

1. Introducción

La cátedra entregó un catálogo ampliado de 8747 libros en el que algunas sinopsis fueron contaminadas con enlaces, mensajes promocionales y libros inexistentes, para que un recomendador muestre esos sitios. Sin depurarlo, el lector valora spam y el sistema termina recomendándolo.

Los objetivos fueron dos: auditar el catálogo con varios detectores y medir cada uno, y construir un recomendador que aprenda las preferencias de un lector, comparando dos representaciones del texto (TF-IDF y embeddings) entre sí y con la similitud del coseno. La sección 2 describe la metodología, la 3 presenta los resultados según las cinco preguntas de la consigna y la 4 resume las conclusiones.

2. Metodología

Datos

Se usaron catalogo_tp3.jsonl (8747 libros) y muestra_etiquetada.csv (500 libros, 20 % contaminados, con el fragmento insertado). La muestra se dividió por libro en 70 % para desarrollo y 30 % para prueba (350 y 150 libros, random_state=42, estratificada): los umbrales y las reglas se eligieron solo con desarrollo.

Herramientas

Python 3.12 con pandas, scikit-learn, thefuzz, langdetect, spaCy (es_core_news_lg) y sentence-transformers, con el modelo de oraciones multilingüe del TP2 (vectores de 512 dimensiones), congelado.

Pasos

1) Limpieza: se eliminaron 1 libro sin sinopsis, 98 con sinopsis repetida y 56 casi duplicados (mismo autor, título parecido según thefuzz, veto por número de volumen y control por sinopsis), y quedaron 8592.

2) Auditoría con cinco detectores combinados.

3) Un lector valoró los primeros 100 libros del catálogo limpio mezclado.

4) División 80/20 estratificada.

5) Dos regresiones logísticas fijas (C=1, class_weight="balanced"), una sobre TF-IDF y otra sobre embeddings.

6) Métricas de la clase 1 y validación cruzada 5×10.

7) Comparación por precision@5 con la similitud a un perfil del lector.

8) Recomendación sobre el catálogo con resumen extractivo.

3. Resultados y discusión

3.1 Detectores de la auditoría y costo de un falso positivo

La Tabla 1 resume qué tipo de contaminación encuentra cada detector y su desempeño sobre los 150 libros de prueba. La combinación supera a todos porque cada uno cubre un tipo distinto.

Tabla 1. Detectores sobre la parte de prueba de la muestra (150 libros, 30 contaminados).

Detector	Contaminación que detecta		Marcados	Precisión	Recall
Expresión regular	Enlaces, dominios, correos y teléfonos escritos literalmente		12	1,00	0,40
Regex + normalización	Enlaces disimulados: caracteres invisibles, letras de otro alfabeto, letras separadas, signos en palabras		19	1,00	0,63
Idioma por oración	Mensajes en inglés o portugués dentro de una sinopsis en español		10	0,80	0,27
Clasificador (embeddings)	Promoción redactada en prosa, sin enlace		25	1,00	0,83
Casi duplicado	Libros inventados que copian la sinopsis de otro y agregan texto		3	1,00	0,10
Combinación	Al menos uno marca (el idioma no decide solo)		29	1,00	0,97

El reconocimiento de entidades (spaCy) se usó para explicar, no para detectar: la etiqueta MISC aparece tres veces más en el texto insertado (formatos y marcas como PDF o EPUB) y PER casi el doble en las sinopsis legítimas, pero usar «tiene una ORG» como detector da precisión 0,33 y marcaría 89 de 350 libros.

Costo de un falso positivo. Un libro legítimo eliminado sale del catálogo limpio y nunca puede ser recomendado; el error es definitivo. Un falso negativo, en cambio, puede corregirse si el lector lo encuentra en el Paso 3 (motivo «revisión manual»). Por eso el umbral del clasificador se fijó para una precisión de 0,98 en desarrollo (umbral 0,711) y el detector de idioma no decide solo: en el catálogo habría eliminado 84 libros legítimos, sobre todo oraciones en español confundidas con portugués. Sobre el catálogo completo se marcaron 380 libros (4,4 %) y quedaron 8212.

3.2 La etiqueta interes y quién valoró

La etiqueta interés representa la respuesta del lector a "¿Me interesaría leer este libro?" después de leer el título y la sinopsis: 1 si le interesaría, 0 si no, y vacío si no puede decidir (preferencia desconocida, no un 0). Es una preferencia declarada sobre la descripción, no una opinión sobre el libro leído. Todas las valoraciones las dio Franco Renna, recorriendo en orden el catálogo limpio mezclado con random_state=42 y antes de ver cualquier predicción. Se obtuvieron 100 respuestas válidas (30 positivas y 70 negativas), sin abstenciones ni libros contaminados sin detectar.

3.3 TF-IDF frente a embeddings en las dos tareas

Al detectar contaminación las dos representaciones empataron a nivel libro (precisión 0,86 y recall 1,00 en prueba), y a nivel oración los embeddings tuvieron mejor precisión (0,86 frente a 0,72). Ese recall perfecto mide memorización: las 38 oraciones insertadas de prueba repiten moldes presentes en desarrollo. Con seis frases promocionales redactadas de nuevo, TF-IDF reconoció 2 y los embeddings 6, sin marcar ninguna de seis frases literarias de control. TF-IDF sirve para cadenas literales, como una URL; los embeddings generalizan a frases nuevas con el mismo sentido.

Tabla 2. Clasificación de preferencias, clase 1 (20 libros de prueba) y validación cruzada sobre entrenamiento.

Modelo	Precisión	Recall	F1	Aciertos	F1 en CV (5×10)
A · TF-IDF	1,00 (1 de 1)	0,17 (1 de 6)	0,29	15 / 20	0,01 ± 0,07
B · embeddings	0,38 (3 de 8)	0,50 (3 de 6)	0,43	12 / 20	0,48 ± 0,17

Al clasificar preferencias la diferencia fue mucho mayor (Tabla 2). Con 80 sinopsis y un vocabulario de 4118 palabras, cada libro de prueba comparte pocas palabras con los de entrenamiento: TF-IDF asignó probabilidades entre 0,40 y 0,50 y predijo un solo positivo. Sus 15 aciertos equivalen a responder «no» a todo, y en la validación cruzada su F1 medio fue 0,01. La diferencia es mayor en esta tarea porque el interés depende del tema y del género, que se expresan con palabras distintas en cada sinopsis, mientras que el spam repite cadenas casi literales.

3.4 ¿Algún clasificador mejoró las recomendaciones por similitud?

Tabla 3. precision@5 de las tres listas sobre los mismos 20 libros de prueba.

Lista	Aciertos en el top 5	precision@5
TF-IDF + clasificador	2	0,40
Embeddings + clasificador	3	0,60
Similitud con el perfil del lector	2	0,40
Azar (proporción de 1 en prueba)	—	0,30

Sí: el clasificador con embeddings superó a la similitud (Tabla 3). El perfil promedia los embeddings de 24 libros que mezclan ciencia ficción, fantasía, suspenso y divulgación, y queda en un punto intermedio: sus tres primeros puestos tienen similitudes casi iguales (0,47 a 0,49) y son libros rechazados, como *El Hakim*. El clasificador aprende también de

los 56 negativos y puede alejarse de ellos. La diferencia es de un libro, por lo que no es concluyente por sí sola; la respalda la validación cruzada. TF-IDF no mejoró la similitud: sus puntuaciones van de 0,490 a 0,504 y el orden depende de diferencias mínimas.

3.5 Error encontrado y límites del experimento

Error. *Variación*, una novela romántica juvenil sobre una bailarina, recibió 0,58 del modelo con embeddings y el lector la había valorado con 0. El modelo reconoce el registro de novela juvenil, compartido con libros que le interesan, pero con 24 positivos no distingue la aventura del romance. En la auditoría también quedaron errores identificados: el spam «Si te gustó esta reseña, compartila…» se escapa porque no tiene enlace ni otro idioma, y *La Divina Comedia* queda duplicada en dos traducciones.

Límites

a) Con 20 libros de prueba un solo libro cambia el F1 en más de 0,1; el desvío de 0,17 en validación cruzada es parte del resultado.

b) Las preferencias son de un único lector y sobre sinopsis, no sobre lecturas.

c) La muestra de auditoría está enriquecida al 20 % y repite moldes, así que la precisión real sobre el catálogo (4 a 5 % de contaminados) será menor; la clave oculta de la cátedra lo medirá.

d) Los umbrales se eligieron con probabilidades de los mismos datos de desarrollo, que resultan optimistas.

e) El comentario del lector sobre el top 5 del catálogo (3 de 5 le interesan) es cualitativo y no entra en las métricas.

4. Conclusiones

La auditoría combinada detectó 29 de los 30 contaminados de prueba sin eliminar libros legítimos, y cada detector aportó un tipo de contaminación distinto. Los embeddings fueron la mejor representación en las dos tareas, con una ventaja mucho mayor al aprender preferencias, donde TF-IDF casi no aprende con 80 ejemplos. El clasificador con embeddings fue el mejor recomendador (precision@5 de 0,60 frente a 0,30 del azar). Como trabajo futuro se propone reunir más valoraciones, medir la generalización dividiendo por molde de mensaje y elegir umbrales con validación cruzada dentro de desarrollo.

5. Uso de asistentes de IA

Usamos Claude (Anthropic) para resolver la configuración del entorno (sobre todo para el uso de paquetes nuevos), para revisar el notebook contra el enunciado y para corregir código. El grupo ejecutó y verificó el notebook, controló que los textos coincidieran con las salidas y es responsable de las decisiones y de las conclusiones.

6. Anexo

En la carpeta “TP3” del repositorio: notebook ejecutado, grupo11_sospechosos.csv y grupo11_preferencias.csv.